

Projet 2 — Analyse des ventes e-commerce

Contexte : Ajout d'une nouvelle gamme de produits → analyse du CA et de la nouvelle segmentation client, avec projection de tendance et préconisations : Comment la nouvelle gamme impacte-t-elle le chiffre d'affaires et la structure de la clientèle, et quelles actions en tirer ?


Mots-clés : saisonnalité · segmentation client · panier moyen · taux de conversion · série temporelle · prévision de CA · up-selling / cross-selling · fidélisation

Compétences mobilisées :

Domaine	Compétence
Analyse statistique	Décomposition du CA (panier moyen × nb visites × taux de conversion)
Analyse statistique	Détection de saisonnalité, analyse de séries temporelles
Data viz	Histogrammes empilés, boxplots, courbes temporelles (Python)
Segmentation	Construction de segments clients (comportementaux/valeur)
Business / recommandation	Traduction des insights en actions marketing : ciblage, fidélisation, up-sell/cross-sell

Outils : Python : pandas, matplotlib/seaborn

Livrable : Rapport d'analyse + préconisations commerciales



Projet 3 — Étude FAO : alimentation dans le monde

Contexte : Analyse de la sous-nutrition mondiale (2013-2017) à partir de 4 bases FAO hétérogènes (disponibilité alimentaire, sous-nutrition, population, aide alimentaire), pour la santé publique / mission type OMS.

Problématique : La capacité mondiale à nourrir la population est-elle suffisante, et pourquoi la sous-nutrition persiste-t-elle malgré cela ? Étude de cas ciblée (manioc en Thaïlande).



Mots-clés : sous-nutrition · disponibilité alimentaire · kcal/jour/personne · aide alimentaire · jointure multi-sources · indicateurs macro-économiques · classement top 10 · étude de cas pays/produit · RGPD (non applicable)

Compétences mobilisées :

Domaine	Compétence
Préparation des données	Fusion/jointure de 4 bases hétérogènes (Zone/Année/Produit/Valeur) sous pandas
Data viz	Histogrammes empilés, podium (top/flop), diagramme spaghetti
Calcul d'indicateurs	Construction d'indicateurs dérivés (kcal/j/p, taux de sous-nutrition, ratio nourriture/production)
Agrégation	Groupby par zone/produit/année, sommes pondérées (kcal disponibles)
Analyse comparative	Classements (sous-nutrition, aide alimentaire, disponibilité par habitant)
Étude de cas	Drill-down pays/produit (Thaïlande-manioc), croisement production/export/nourriture
Conformité	Identification du périmètre RGPD
Synthèse	Formulation de conclusions argumentées et de facteurs explicatifs multicausaux (logistique, politique, sécurité)

Outils : Python (pandas), notebook Jupyter

Livrable : Notebook Python + rapport d'analyse avec conclusion



Projet 5 — DATAImmo : modélisation et analyse SQL du marché immobilier

Contexte : Pour une agence immobilière, centraliser 3 sources hétérogènes (DVF, INSEE démographie, référentiel géographique) dans une base relationnelle normalisée, pour analyser le marché immobilier français.

Problématique : Comment structurer et interroger des données transactionnelles + démographiques + géographiques hétérogènes pour produire des indicateurs de marché (volumes, prix au m², typologie) fiables et gouvernés (RGPD, sauvegarde) ?

Mots-clés : modélisation relationnelle · schéma normalisé · dictionnaire de données · SQLite · jointures multi-tables · CTE (WITH ... AS (...)) · fonctions fenêtrées (ROW_NUMBER) · agrégation SQL · RGPD · stratégie de sauvegarde · Open Data / Etalab

Compétences mobilisées :

Domaine	Compétence
Modélisation de données	Conception d'un schéma relationnel normalisé (clés primaires/étrangères) à partir de sources hétérogènes
Documentation	Rédaction d'un dictionnaire de données
SQL	Jointures multi-tables, sous-requêtes corrélées, CTE (WITH), fonctions fenêtrées (ROW_NUMBER OVER PARTITION)
SQL	Agrégations (COUNT, AVG, ratios, taux d'évolution trimestriel), calculs dérivés (prix au m ²)
Gouvernance des données	Analyse de conformité RGPD (licéité, minimisation, anonymisation par agrégation)
Gouvernance des données	Définition d'une stratégie de sauvegarde/restauration (versioning, sauvegardes différentielles)
Gestion de projet	Formalisation d'un cadrage de mission (mail de mission, POC avant généralisation)

Outils : SQLite, SQL, Excel, Power Query

Livrable : Schéma relationnel + dictionnaire de données + base SQLite + requêtes SQL documentées

Projet 6 — Bottleneck : ERP/Web e-commerce vins & champagnes

Contexte : Pour ESNDData, fusion de deux systèmes (ERP prix/achat/stock et Web ventes/catégories) via jointure sur clés `product_id/id_web`, sur une fenêtre de données limitée.

Problématique : La qualité des données ERP/Web permet-elle une analyse fiable de la structure des ventes, et quels axes d'amélioration business (gestion de gamme, stock, marge) en tirer malgré une fenêtre réduite ?





Mots-clés : qualité de données · nettoyage · jointure de sources hétérogènes · feature engineering · détection d'outliers (IQR, z-score) · loi de Pareto (80/20) · coefficient de Gini · valorisation de stock · rotation de stock · saisonnalité · analyse de marge

Compétences mobilisées :

Domaine	Compétence
Qualité des données	Audit structuré (comptage lignes/colonnes, doublons, valeurs manquantes, incohérences prix/stock) par table
Nettoyage	Traitement différencié par type d'anomalie (suppression, correction à 0, filtrage par type produit), Archivage des lignes en erreurs.
Fusion de données	Jointure de sources hétérogènes sur clé, contrôle du taux de perte à la jointure
Feature engineering	Création d'indicateurs dérivés (part de CA cumulée, cumul quantités, mois de stock, prix HT, marge totale)
Analyse statistique	Détection d'outliers par IQR et par z-score, interprétation métier des extrêmes (produits premium)
Analyse business	Analyse de concentration (Pareto 80/20) et d'inégalité (coefficient de Gini) sur CA, ventes et marge
Analyse business	Analyse de rotation de stock (mois de stock, flop 10, valorisation du stock)
Restitution	Export de livrable exploitable (xlsx), recommandations priorisées, identification explicite des limites de l'étude

Outils : Python (nettoyage/feature engineering), Excel

Livrable : Dataframe/fichier xlsx nettoyé et enrichi (714 lignes × 13 colonnes) + support de présentation avec analyses et recommandations



Coefficient de Gini = 0.76

Projet 7 — Power BI : suivi d'avancement de projets IT & Marketing

Contexte : Suivi international sur 4 ans de projets Marketing (4 phases) et IT (6 phases), avec alerte automatique dès 15 % d'écart prévisionnel/réel sur 3 KPI (livrables, durée, coût), pour 3 profils utilisateurs (DG, directeurs régionaux, directeurs de pays).

Problématique : Comment structurer et automatiser un modèle de données volumineux et hétérogène en schéma en étoile pour produire un tableau de bord multi-niveaux avec alerte dynamique, et personnalisé par rôle ?


Mots-clés : schéma en étoile · 3NF · Power Query · DAX · nettoyage dynamique · mesures/KPI · code couleur dynamique (alerte) · table calendrier · RLS/gestion des rôles · histogramme groupé et empilé · dette journalière

Compétences mobilisées :

Domaine	Compétence
Modélisation de données	Reconstruction d'un schéma en étoile normalisé (extraction de dimensions pays/région/projet, table de faits phases agrégée)
ETL	Nettoyage dynamique automatisé en Power Query, validation par tests d'automatisation
DAX	Écriture de mesures d'alerte (10 mesures intermédiaires, phases 1-4 et A-F), gestion de la compatibilité/maintenabilité du code
DAX / modélisation avancée	Construction d'une table calendrier avec logique d'intervalle (phase active si date début < jour < date fin), optimisation de performance
Data viz	Codage couleur dynamique par niveau d'alerte (calcul manuel du dégradé — la carte choroplèthe étant trop limitée)
Data viz	Histogrammes groupés/empilés avec caractérisation visuelle du dépassement (seuil 15 %)
UX / gouvernance	Conception d'une interface multi-rôles avec restriction de périmètre (bridage régional), navigation par drill-down (pays → projet → phase)
Indicateur métier	Construction d'un indicateur composite ("dette journalière") pour mesurer l'écart cumulé prévisionnel/réel dans le temps

Outils : Power BI, Power Query, DAX

Livrable : Tableau de bord Power BI multi-pages (vue globale/régionale, détail projet, vue temporelle) avec gestion des rôles



Fiche Projet 8 — Analyse démographique des étudiants OpenClassrooms (dbt/Snowflake)

Contexte : Pipeline dbt/Snowflake sur 4 647 étudiants OpenClassrooms (2022-2025), enrichis par les données INSEE (population 2019), pour un profilage démographique et une analyse de captation par région.

Problématique : Qui sont les étudiants OpenClassrooms (âge, genre, région, évolution par promotion), et quels leviers de croissance/diversification en tirer pour le recrutement ?



Mots-clés : pipeline ELT · dbt · Snowflake · staging/marts · analyse univariée/multivariée · enrichissement démographique (INSEE) · taux de captation pour 10 000 habitants · Pareto · imputation de données manquantes · RGPD (minimisation, durée de conservation)

Compétences mobilisées :

Domaine	Compétence
Ingénierie de données	Pipeline ELT : import SQL dynamique vers Snowflake, transformation via modèles dbt (YAML), architecture staging → agrégation
Enrichissement de données	Croisement avec données externes (population INSEE) , normalisation des volumes bruts en taux pour 10 000 habitants.
Analyse statistique	Analyse univariée (promotion, région, âge, genre) et multivariée (âge×promotion, genre×région)
Traitement des données manquantes	Imputation appliquée au croisement genre×région, quantification explicite du taux « genre » non-renseigné (26,8 %)
Analyse business	Analyse de Pareto multi-variable (101 combinaisons/297 = 80 % des étudiants), identification de profil dominant
Analyse comparative	Benchmark vs moyenne nationale (parité femmes/hommes)
Gouvernance des données	Analyse RGPD post-publication (minimisation, durée de conservation des identifiants, registre des traitements)
Restitution	Storytelling data avec recommandations stratégiques priorisées et numérotées

Outils : SQL, dbt, Snowflake, Python

Livrable : Pipeline dbt versionné (GitHub). Présentation d'analyse avec recommandations



Fiche Projet 9 — Lapage : indicateurs de vente et comportement client e-commerce

Contexte : Analyse de 24 mois d'activité d'un e-commerce de livres/produits culturels (Lapage), 8 621 clients, 3 286 produits, 687 534 transactions, incluant la caractérisation de segments B2B dans une base B2C.

Problématique : Quelle est la structure réelle du CA et de la clientèle (concentration, segments, tendances), et quelles anomalies (doublons, B2B non déclarés, churn) faut-il isoler pour ne pas biaiser l'analyse ?


Mots-clés : fusion multi-tables · qualité de données · doublons · moyenne mobile · régression par morceaux · loi de Pareto · coefficient de Gini · courbe de Lorenz · test du Chi² · Cramér's V · corrélation de Spearman · test de Kruskal-Wallis · eta carré · détection d'outliers · détection B2B · analyse de churn

Compétences mobilisées :

Domaine	Compétence
Préparation des données	Fusion de 3 sources (clients, produits, sessions), suppression d'entités non liées, contrôle RGPD
Qualité des données	Détection d'anomalies structurelles (57 996 lignes dupliquées identifiées par clé composite id_client/timeOnly/année)
Analyse statistique descriptive	Répartition par catégorie, indicateurs clés par dimension (client, produit, session)
Séries temporelles	Moyenne mobile pour lissage de tendance, régression par morceaux (détection de rupture de tendance mars 2022)
Analyse de concentration	Pareto (2,9 %/20 %, 25,4 %/80 %), coefficient de Gini (0,688), courbe de Lorenz
Statistiques inférentielles	Test du Chi ² + Cramér's V (association entre variables catégorielles, distinction significativité/taille d'effet)
Statistiques inférentielles	Corrélation de Spearman (âge vs CA, fréquence, panier moyen — non-paramétrique, cohérent avec données non gaussiennes)
Statistiques inférentielles	Test de Kruskal-Wallis + eta carré (comparaison de médianes entre catégories, quantification de la taille d'effet)
Détection d'outliers / segmentation métier	Identification de clients B2B par seuils de CA et de fréquence d'achat, distinction avec l'analyse B2C.
Analyse de rétention	Analyse de churn / acquisition (dates de premier et dernier achat)

Outils : Python (pandas, scipy)

Livrable : Rapport d'analyse avec dashboard de KPI, tests statistiques documentés, recommandations de segmentation



Fiche Projet 10 — DWFA : dashboard Tableau sur l'accès à l'eau potable

Contexte : Mission de consulting pour l'ONG DWFA (accès à l'eau potable), en amont d'une décision d'investissement conditionnée à un financement, sur l'un de ses 3 domaines d'expertise (création de services, modernisation, consulting politique publique) dans un pays à déterminer.

Problématique : Quels pays présentent des difficultés d'accès à l'eau potable, et sur lesquels concentrer l'investissement, à travers un tableau de bord multi-niveaux (monde → continent → pays) couvrant les 3 domaines d'expertise ?


Mots-clés : cahier des charges client · brief de mission · sélection d'indicateurs · dashboard multi-niveaux (drill-down) · navigation par survol (hover) · carte géographique interactive · dégradé de couleur (heatmap) · Tableau Story · Tableau Public · accessibilité · dictionnaire de données · sources OMS/FAO

Compétences mobilisées :

Domaine	Compétence
Cadrage de mission	Traduction d'un brief client (mail + compte-rendu de réunion) en spécifications d'indicateurs et de vues
Sélection d'indicateurs	Choix d'indicateurs pertinents par domaine d'expertise (accès à l'eau, logistique, politique) à partir d'un dictionnaire de données et de sources externes (OMS, FAO)
Conception UX / dataviz	Conception d'un dashboard à 3 niveaux de granularité (monde/continent, continent/pays, détail pays) avec logique de drill-down cohérente
Conception UX / dataviz	Interaction par survol (highlight dynamique carte ↔ indicateurs périphériques), inspirée d'un modèle de référence (Harvard)
Data viz	Carte géographique avec dégradé de couleur d'intensité, disposition centrale carte + indicateurs en périphérie
Data viz	Vue temporelle (évolution accès à l'eau potable / industrialisation) sur la page de détail pays
Tableau	Construction d'une histoire Tableau (story), logique de navigation entre feuilles/niveaux
Accessibilité	Prise en compte de contraintes d'accessibilité dans la conception du dashboard
Publication	Partage via Tableau Public

Outils : Tableau (Desktop + Public)

Livable : Dashboard Tableau interactif à 3 vues (histoire Tableau), publié sur Tableau Public



Projet 11 — La Poule qui chante : segmentation de marchés export par ACP & K-Means

Contexte : Pour un exportateur de poulet bio français, segmentation stratégique de 127 pays selon des variables PESTEL (FAO, World Bank, UNDP (Unit. Nat. dev. Prog.)) afin d'identifier les marchés prioritaires pour une stratégie d'export.

Problématique : Quels pays constituent des marchés d'export prioritaires, à surveiller, ou non exploitables à court terme pour du poulet bio, et comment affiner cette segmentation à l'intérieur du groupe des marchés matures ?


Mots-clés : cadre PESTEL · ACP (analyse en composantes principales) · K-Means · CAH (classification ascendante hiérarchique) · méthode du coude (Elbow) · indice de Calinski-Harabasz · score de Silhouette · re-clustering intra-cluster · normalisation per capita · variance expliquée · segmentation stratégique de marché

Compétences mobilisées :

Domaine	Compétence
Préparation des données	Réconciliation de noms de pays entre 3 sources hétérogènes (FAO, World Bank, UNDP), gestion des valeurs manquantes
Feature engineering	Normalisation per capita pour neutraliser l'effet taille de population
Choix méthodologique	Décision assumée de conserver les outliers (richesse informationnelle) plutôt que les exclure
Réduction de dimension	ACP sur 8 variables PESTEL, interprétation économique des axes factoriels principaux (F1 = maturité, F2 = appétence produit)
Clustering	K-Means avec triangulation de 3 méthodes de choix du nombre de clusters (Elbow, Calinski-Harabasz, Silhouette) + validation croisée par CAH
Clustering avancé	Re-clustering intra-cluster pour lever une hétérogénéité résiduelle non détectée à l'échelle globale
Analyse stratégique	Traduction des clusters en recommandations d'action différenciées (ciblage immédiat / veille / horizon long terme)
Analytique métier	Décision méthodologique : k=4 techniquement optimal mais k=3 retenu pour cohérence interprétative et CAH.

Outils : Python (scikit-learn), Tableau Desktop

Livrable : Rapport de segmentation en 2 parties (clustering global 127 pays + re-clustering du cluster 1) avec recommandations priorisées, dashboard Tableau



Fiche Projet 12 — ONCFM : détection automatique de faux billets

Contexte : Pour l'ONCFM (organisme de lutte contre le faux-monnayage), construction et comparaison de 4 algorithmes de classification sur 1 500 billets labellisés (6 dimensions géométriques), avec système d'indice de confiance pour signaler les cas ambigus.

Problématique : Quel algorithme offre le meilleur compromis performance/interprétabilité/déployabilité pour classer automatiquement des billets, et comment quantifier la fiabilité de chaque prédiction?

Mots-clés : classification supervisée/non-supervisée · régression logistique · Random Forest · KNN · K-Means · imputation par médiane · méthode IQR · matrice de confusion · indice de confiance · indépendance des moteurs · stacking / méta-modèle · pair plot · pipeline de production (scaler + modèles sérialisés)

Compétences mobilisées :

Domaine	Compétence
Préparation des données	Imputation ciblée par médiane de groupe, détection d'outliers par IQR sans suppression systématique (choix documenté)
Analyse exploratoire	Pair plot : séparabilité des distributions et corrélation entre classes
Machine learning supervisé ou non	Entraînement et comparaison de 4 algorithmes de nature différente (linéaire, ensembliste, local, clustering)
Évaluation de modèles	Accuracy, matrices de confusion, comparaison faux positifs/négatifs par modèle
Quantification de l'incertitude	Construction d'indices de confiance par moteur (probabilité, proportion de votes, ratio de distances...), avec évaluation de leur pouvoir discriminant
Statistique avancée	Une hypothèse de redondance entre K-Means et la régression logistique (dans notre distribution) a conduit à écarter K-means pour le stacking.
Analyse de cas limites	Diagnostic individualisé des désaccords inter-modèles, identification d'un label toujours mal prédit dans les données sources (erreur de labélisation?)
Méthodologie avancée	Conception d'un pipeline de stacking (méta-modèle), avec split train/test_confiance/test_final et évaluation critique de sa faisabilité.
MLOps / déploiement	Sérialisation des modèles et du scaler (.pkl), notebook de prédiction en production (predict.ipynb)
Esprit critique	Identification explicite des limites (volume, corrélation des moteurs, erreur indétectable à haute confiance)

Outils : Python (scikit-learn, pandas, matplotlib/seaborn)

Livrable : Pipeline de notebooks modulaires (split, entraînement ×4, prédiction) + modèles sérialisés + rapport comparatif avec 21 slides

